

DEEP LEARNING 2026 · PROYECTO 2

Eryndor

Guardianes del Velo

Diseño generativo de personajes para un RPG pixel art de aventura y magia

Universidad del Valle de Guatemala

Deep Learning · Sección 30

Integrantes

Pablo Daniel Barillas Moreno

Wilson Alejandro Calderón

Repositorio

github.com/DanielBarillasM/Proyecto-2_Grupo-1_DLYSI_Sec-30

Resumen ejecutivo

Este proyecto estudia si una GAN entrenada sobre sprites abiertos y visualmente consistentes puede generar personajes plausibles, diversos y defendibles como nuevos dentro del universo de Eryndor. Se construyó un dataset determinista de 4,096 imágenes RGB de 64×64 píxeles a partir de recursos Liberated Pixel Cup, con cero archivos faltantes, cero hashes duplicados y atribución resuelta para las 254 capas utilizadas.

Se entrenaron tres variantes DCGAN durante 60 épocas bajo un protocolo controlado: BCE base, hinge loss y BCE con normalización espectral en el discriminador. Hinge sufrió colapso de modo; la variante con normalización espectral mantuvo la mayor diversidad final y fue seleccionada. A partir de 200 candidatos se eligieron diez mediante una regla pre-registrada de calidad, novedad y diversidad. Los diez PNG son únicos, tienen vectores latentes persistidos y regeneran con diferencia RGB máxima igual a cero.

DATASET

4,096

ENTRENAMIENTO

60/60

SELECCIÓN

10/200

DELTA RGB

0

Contents

1	Problema, universo y criterio de éxito	2
2	Dataset, procedencia y preparación	2
2.1	Fuente y licencias	2
2.2	Pipeline reproducible	2
3	Arquitectura y protocolo experimental	3
4	Resultados de entrenamiento	4
5	Novedad, selección y galería final	5
5.1	Auditoría de vecinos	6
5.2	Selección transparente	6
5.3	Reflexión final	8
6	Reproducibilidad y trazabilidad	8
7	Conclusiones y limitaciones	8
8	Ética, atribución y uso de IA	8

1 Problema, universo y criterio de éxito

La pregunta central fue: *¿puede una GAN entrenada sobre sprites abiertos y consistentes generar personajes de Eryndor que sean plausibles, diversos y distintos de sus vecinos más cercanos en entrenamiento?*

Eryndor es un mundo de fantasía fracturado por la Ruptura Celeste. La magia se solidifica en minerales luminosos y sus guardianes recorren fortalezas derruidas, bosques húmedos y observatorios olvidados para cerrar grietas arcanas. El lenguaje visual usa pixel art detallado, cuerpo completo, perspectiva ortográfica elevada, materiales gastados y una paleta oscura con acentos cian, oro y amatista.

El éxito exigía: código regenerable; diez personajes distintos; evolución visible con ruido fijo; ausencia de copias exactas frente al entrenamiento; comparación de experimentos cambiando una sola variable; y trazabilidad desde checkpoint y vector z hasta cada PNG.

2 Dataset, procedencia y preparación

2.1 Fuente y licencias

Las composiciones derivan del *Universal LPC Spritesheet Character Generator*. El commit fijado fue:

```
4963a69795255fb15a934c47f478a8bdcf3668f5
```

LPC integra activos bajo licencias abiertas como CC0, CC-BY, CC-BY-SA, OGA-BY y GPL. El repositorio conserva autores, licencias y URL por capa en `docs/LPC_CREDITS_USED.csv`; se resolvieron 254 de 254 créditos.

2.2 Pipeline reproducible

La semilla de dataset fue 2026. El pipeline aplicó composición alfa de cuerpo, ropa, cabello, accesorios y armas; extrajo la pose frontal de 64×64 ; fijó un fondo obsidiana; y calculó SHA-256 sobre píxeles RGB antes de aceptar cada imagen. El resultado fue:

- 4,096 imágenes RGB, cero faltantes y cero hashes duplicados;
- 2,060 cuerpos `male` y 2,036 `female`;
- 44 estilos de cabello y 18 estilos de torso;
- ocupación media de primer plano de 23.18%, con rango 16.04%–31.57%;
- lotes `float32` de forma `[64, 3, 64, 64]` normalizados a `[-1, 1]`.



Figure 1: Muestra determinista del dataset preparado.

Limitación del corpus. El dataset es composicional, comparte bases anatómicas y contiene una sola pose frontal. Esto favorece control visual y legal, pero limita la diversidad estructural que la GAN puede aprender.

3 Arquitectura y protocolo experimental

El generador proyecta $z \in \mathbb{R}^{128}$ desde 1×1 hasta una imagen RGB de 64×64 mediante cinco convoluciones transpuestas, BatchNorm, ReLU y salida $\tanh$. El discriminador reduce la imagen a un logit escalar con cinco convoluciones, LeakyReLU 0.2 y BatchNorm desde el segundo bloque. El generador contiene 3,806,080 parámetros y el discriminador 2,765,568.

Se eligió DCGAN porque el corpus es homogéneo y tiene resolución fija de 64×64 , la arquitectura cabe

en los recursos de Google Colab y permite aislar el efecto de la pérdida y de la estabilización sin cambiar simultáneamente el modelo. Es una elección de control y trazabilidad experimental, no una afirmación de estado del arte.

La configuración común fue batch 64, Adam con $lr = 2 \times 10^{-4}$, $\beta_1 = 0.5$, $\beta_2 = 0.999$, semilla de modelo 42, ruido fijo 777, 60 épocas y checkpoints reanudables.

Table 1: Experimentos controlados y pre-registrados.

ID	Pérdida	Estabilización	Hipótesis y criterio previo
A	BCE no saturante	Baseline	Creemos que BCE producirá siluetas reconocibles porque el dataset es consistente. Lo consideraremos útil si el ruido fijo progresa sin converger a una apariencia.
B	Hinge	Igual a A	Creemos que hinge mejorará rasgos porque mantiene gradientes útiles. Lo consideraremos útil si mejora calidad y diversidad sin acercarse al entrenamiento.
C	BCE no saturante	Spectral norm en D	Creemos que normalización espectral estabilizará a D porque limita sus capas. Lo consideraremos útil si reduce su dominio y sostiene el ruido fijo.

Solo cambió la pérdida en B y la estabilización en C. Datos, arquitectura, semillas, optimizadores, épocas y ruido fijo permanecieron iguales.



4 Resultados de entrenamiento

Los tres experimentos completaron 60 épocas. La auditoría consolidó 180 registros por época y 11,520 pasos sin duplicados, faltantes ni valores no finitos.

Table 2: Métricas de la época final.

Experimento	L_D	L_G	Logit real	Logit falso G	Diversidad
BCE base	0.0789	5.6369	5.1900	-5.6287	0.2585
Hinge	0.0000	8.1271	5.0046	-8.1271	0.0136
BCE + spectral norm	0.1905	7.0557	5.4518	-7.0458	0.2659

Las escalas de BCE y hinge no son directamente comparables. La interpretación combinó la trayectoria de cada variante, los mismos 16 vectores fijos, diversidad y revisión visual. Hinge acumuló 23 épocas con $L_D < 10^{-3}$ y terminó con diversidad 0.0136, evidencia de colapso. BCE base produjo personajes reconocibles. C sostuvo la mayor diversidad final, 0.2659, y la mayor media de las últimas diez épocas, 0.2671; por ello se convirtió en el modelo final y luego fue confirmado por las auditorías de fases 9-11.



5 Novedad, selección y galería final

5.1 Auditoría de vecinos

La fase 9 comparó 16 muestras de ruido fijo contra las 4,096 imágenes reales mediante ResNet18 IMAGENET1K_V1 sin capa final, similitud coseno y MSE. El coseno medio fue 0.7660; el MSE medio, 0.02615. No se encontraron duplicados exactos ni casos que cumplieran simultáneamente la bandera de revisión $\text{coseno} \geq 0.95$ y $\text{MSE} \leq 0.01$.

5.2 Selección transparente

Con semilla 20261011, el modelo final generó 200 candidatos. Los límites técnicos de ocupación y contraste se derivaron del dataset. Noventa y siete candidatos fueron elegibles. El primero se eligió con 70% novedad y 30% calidad; los nueve restantes, con 55% diversidad interna, 30% novedad y 15% calidad. No hubo sustitución manual. La tasa declarada fue $10/200 = 5\%$.

Los índices seleccionados fueron 100, 35, 144, 141, 114, 15, 48, 20, 0 y 39. Su coseno medio frente al vecino real fue 0.7563 y el MSE medio 0.02152.



Figure 4: Galería final de diez personajes generados por la GAN del equipo.

Table 3: Personajes y métricas frente al vecino real.

#	Nombre	Rol	Candidato	Coseno	MSE
1	Aelira	Oráculo del Velo	100	0.6981	0.01489
2	Bram	Guardián rúnico	35	0.7911	0.01485
3	Cyran	Arcanista de ceniza	144	0.7676	0.03245
4	Delyra	Exploradora del musgo	141	0.7593	0.02025
5	Edrik	Alquimista solar	114	0.7449	0.02029
6	Faelor	Centinela de amatista	15	0.7660	0.03430
7	Ilyne	Tejedora de grietas	48	0.7426	0.01655
8	Kael	Custodio de la brasa	20	0.7482	0.01530

#	Nombre	Rol	Candidato	Coseno	MSE
9	Mireth	Cartógrafa astral	0	0.7804	0.02499
10	Nyra	Vigía del abismo	39	0.7644	0.02135




Figure 5: Cada personaje final junto a su vecino más cercano del entrenamiento.

5.3 Reflexión final

Bram, Guardián rúnico, es el personaje más difícil de defender como nuevo porque alcanza el mayor coseno, 0.7911, frente a su vecino real; su MSE es 0.01485. Comparte la silueta global, la pose y parte de la gramática cromática del conjunto, aunque la composición generada no es una copia exacta.

Este caso muestra que la GAN aprendió bien la gramática frontal restringida de LPC y recombino atributos superficiales. También revela el límite del aprendizaje: con una única pose y anatomías compartidas, la diversidad estructural es reducida incluso cuando no existe duplicación exacta.

6 Reproducibilidad y trazabilidad

Cada PNG final se vincula con su vector z , índice de candidato, semilla, SHA-256, checkpoint, vecino real y métricas en `galeria/manifest.csv`. `galeria/latents.npz` tiene forma $[10, 128, 1, 1]$. La selección coincide con fase 10, los diez hashes son únicos y la regeneración desde checkpoint produce diferencia RGB máxima igual a cero.

El código, notebooks y artefactos versionados se encuentran en el [repositorio GitHub del proyecto](#).

El checkpoint oficial es `checkpoints/bce_spectral_norm/latest.pt`, época interna 60, con SHA-256:

```
b032a9fa92e719b0500e54a7ee14d5c1a691386bb32459d38807305b699b7f80
```

Git ignora los checkpoints pesados. El peso oficial se publica en [GitHub Release v1.0.0](#); debe guardarse como `checkpoints/bce_spectral_norm/latest.pt` y validarse contra el hash anterior. Las semillas fueron 2026 para datos, 42 para modelo, 777 para ruido fijo y 20261011 para la galería.

7 Conclusiones y limitaciones

1. La normalización espectral fue la intervención más útil dentro del protocolo controlado: C conservó diversidad 0.2659 y produjo la galería final.
2. Hinge no mejoró el resultado bajo esta configuración; su diversidad 0.0136 y el dominio sostenido de D son consistentes con colapso de modo.
3. La galería es reproducible y no contiene duplicados exactos del entrenamiento, pero esto no equivale a una prueba absoluta de originalidad artística.
4. ResNet18 y MSE aportan una auditoría cuantitativa; ResNet18 no fue entrenada específicamente para pixel art.
5. Una sola pose, bases anatómicas compartidas y una corrida completa por variante limitan la generalización de las conclusiones.

8 Ética, atribución y uso de IA

Ninguna imagen de la galería procede de un generador externo. Se utilizó asistencia de IA para estructurar el repositorio, proponer y revisar código, apoyar la dirección creativa y documentar la metodología. Los

integrantes verificaron las ejecuciones y conservan la responsabilidad sobre la interpretación y defensa del trabajo.

La organización de la auditoría reproducible siguió procedimientos de habilidades científicas descritos por Kassis et al. (2026). La matriz completa que conecta requisitos, evidencia, conclusión y limitación está en docs/MATRIZ_EVIDENCIAS.md.

Referencias

References

- [1] I. Goodfellow et al. *Generative Adversarial Nets*. Advances in Neural Information Processing Systems, 2014.
- [2] A. Radford, L. Metz y S. Chintala. *Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks*. ICLR, 2016.
- [3] T. Miyato, T. Kataoka, M. Koyama y Y. Yoshida. *Spectral Normalization for Generative Adversarial Networks*. ICLR, 2018.
- [4] T. Kassis, V. Agarwal, Y. He, D. Patel y A. M. Brueckner. *Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents*. arXiv:2609.00065, 2026. <https://arxiv.org/abs/2609.00065>
- [5] Universal LPC Spritesheet Character Generator. <https://github.com/LiberatedPixelCup/Universal-LPC-Spritesheet-Character-Generator>
- [6] Liberated Pixel Cup Style Guide. <https://lpc.opengameart.org/static/LPC-Style-Guide/build/styleguide.html>